

Einführung in AI Safety I

Warum macht die KI nicht immer das, was wir wollen?

Aleksandra Shcherbakova

03.11.2026

AI Safety Tübingen

Warum macht die KI nicht das, was wir wollen?

1 Was passiert, wenn wir KI nutzen?

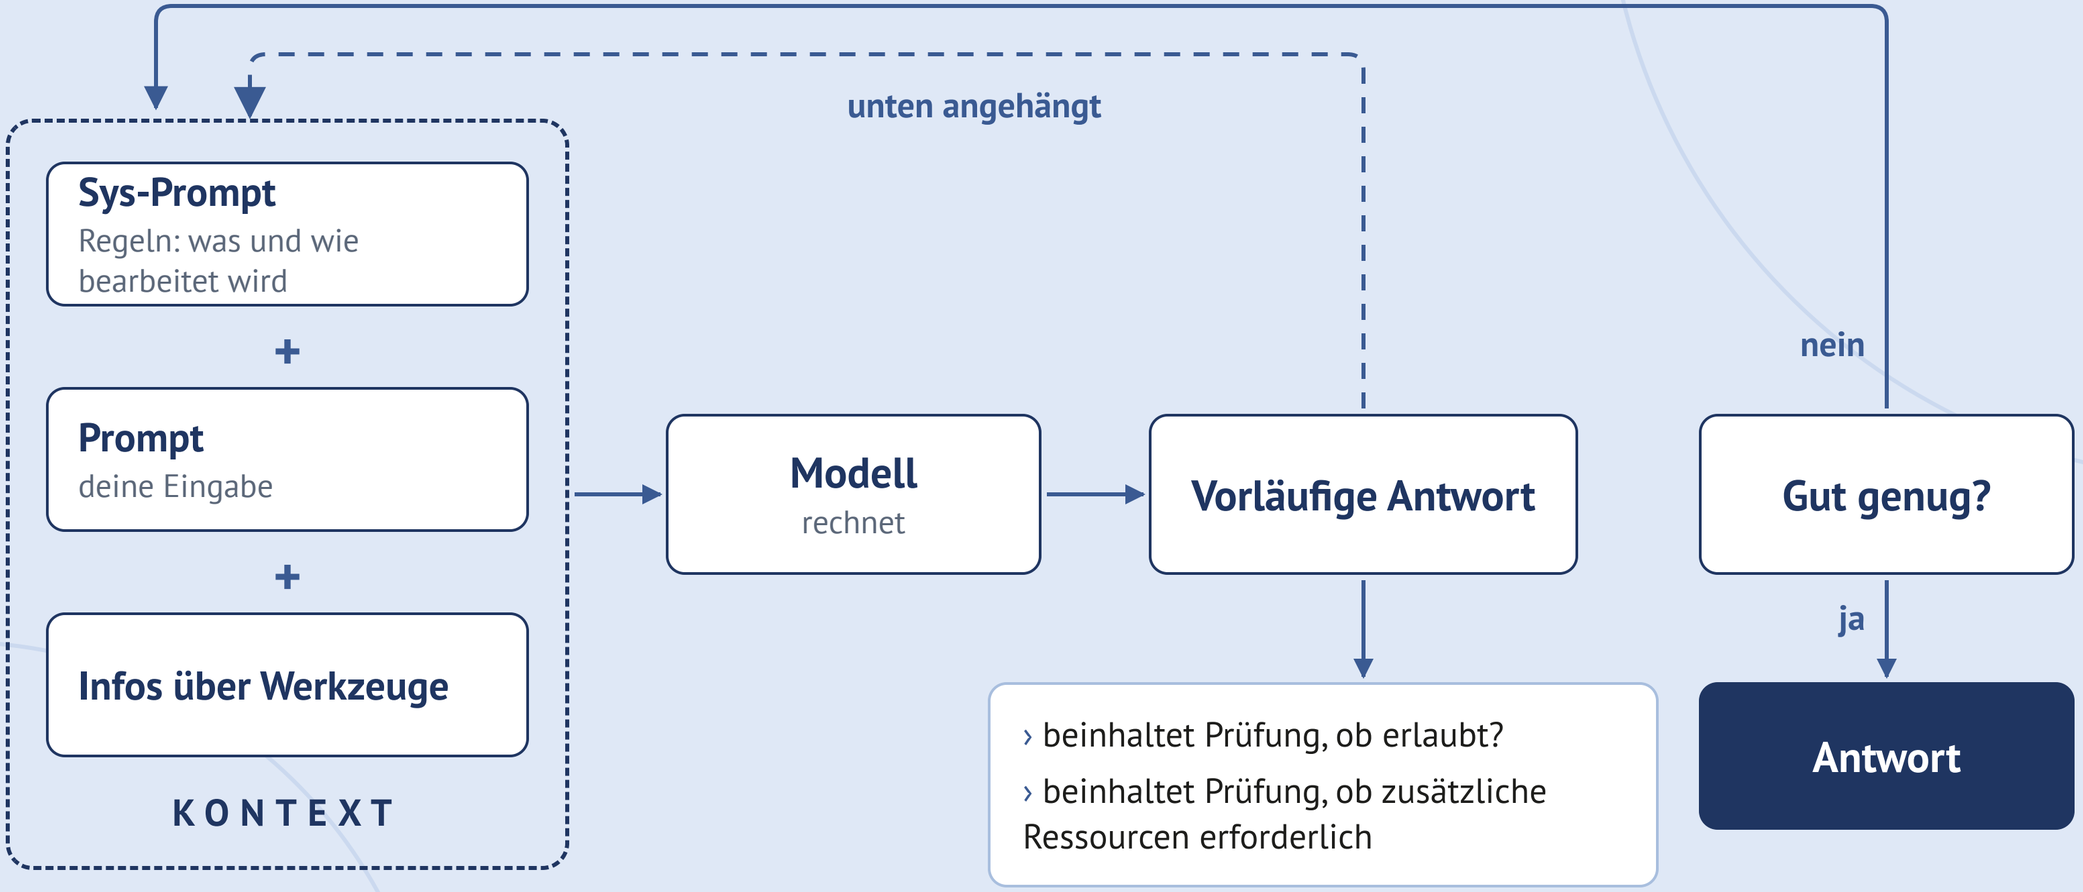
2 Was ist der Output einer KI?

3 Wie wird der Output gezüchtet?

4 Fehlerquellen

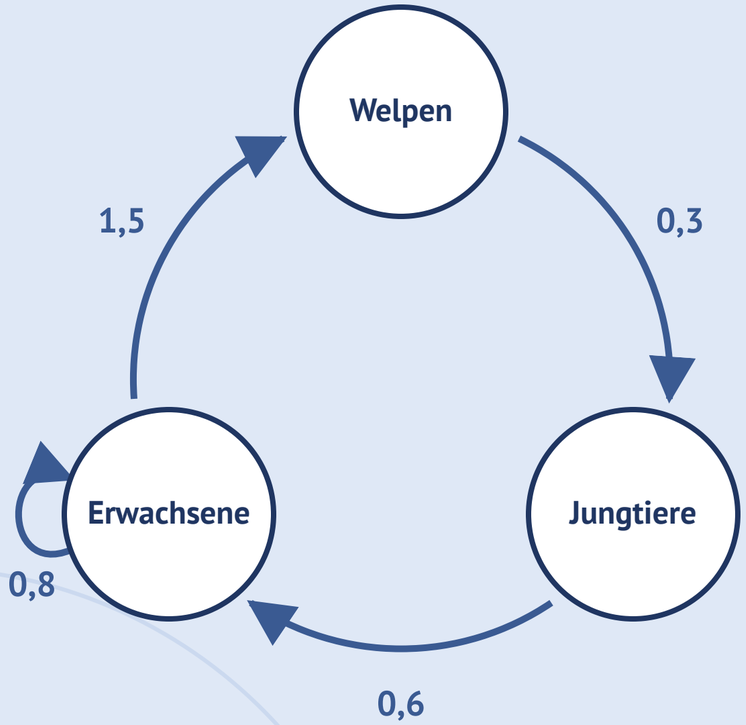
5 Gesprächsrunde

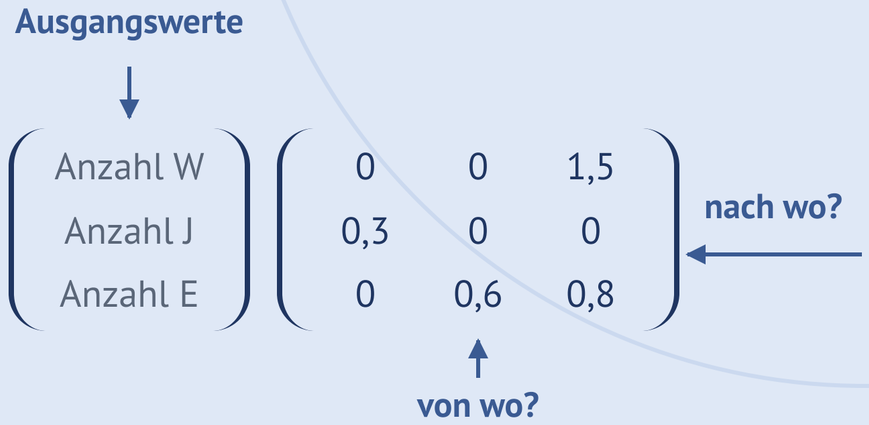
Was passiert, wenn wir KI nutzen?



Was ist der Output der KI?

Konkret: Large Language Model



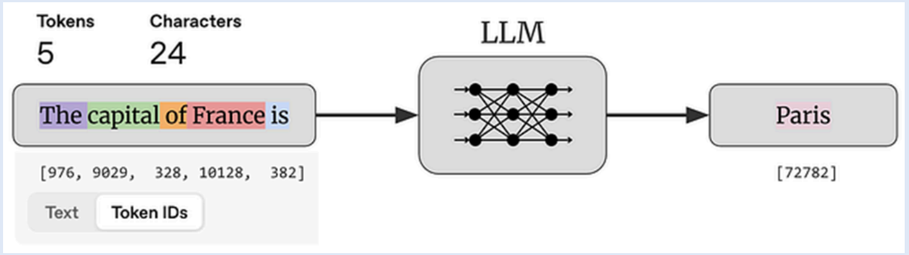


LLM: Was ist das nächst-wahrscheinlichste Wort?

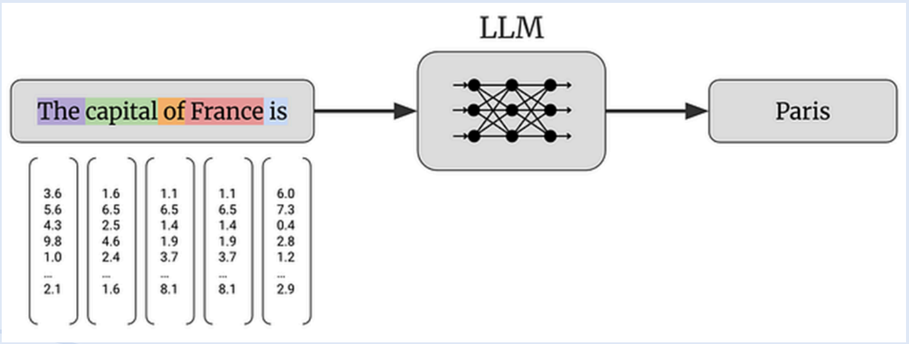
Wie sieht die Wolfspopulation in einem Jahr aus?

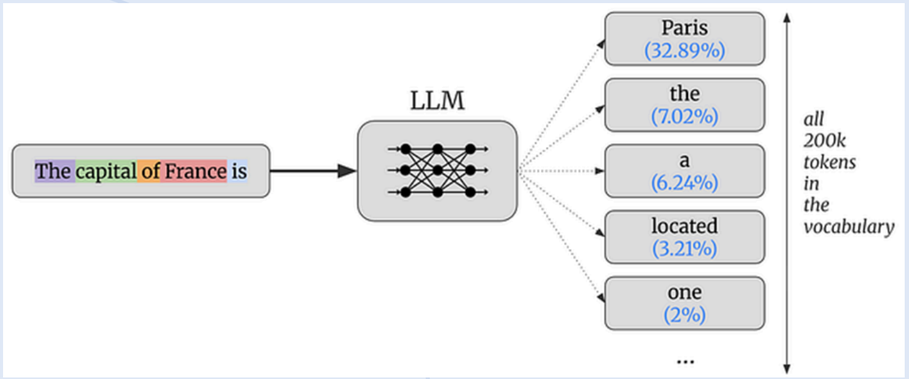
Was ist der Output der KI?

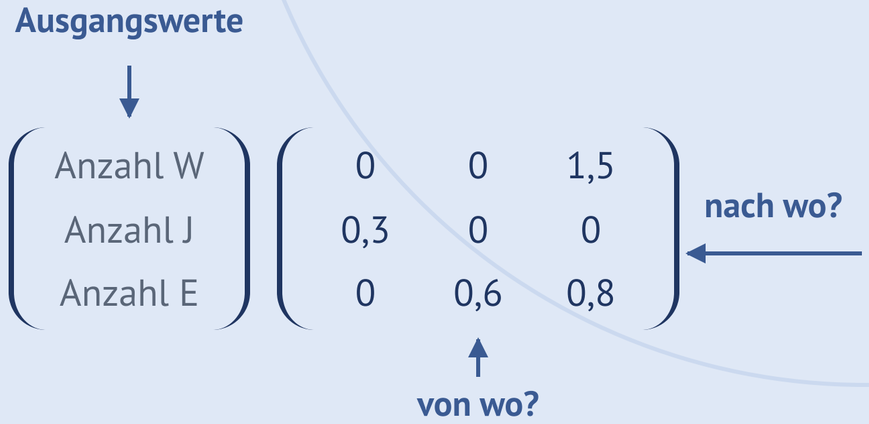
Konkret: Large Language Model



[1]







LLM: Was ist das nächst-wahrscheinlichste Wort?

Wie wird der Output „gezüchtet“?

Data Preparation

1 Data Collection

› Text, Bilder, Video, Code, …

2 Data Processing

› bereinigen

› „Tokenisieren“: jedes Wortteil kriegt eine Registernummer

Pre-Training: Basismodell erstellen

3 Model Design

› Festlegen der Architektur

› Ziel fürs Modell: möglichst richtiges Ergebnis

› Kernfunktion: korrigiert sich selbst

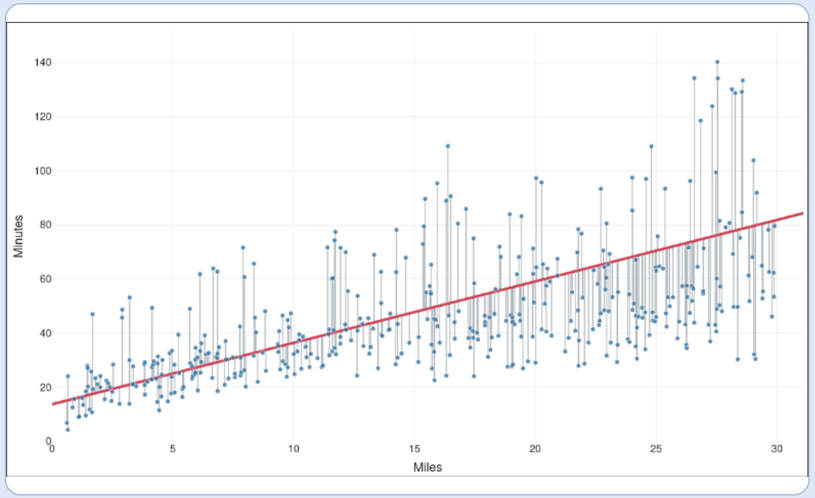
4 Pre-Training

› Input: alle Tokens + sehr viel Rechenleistung

› Welches nächste Token ist am wahrscheinlichsten?

› Sinnebenen und Wahrscheinlichkeiten entwickeln sich: „Embedding“

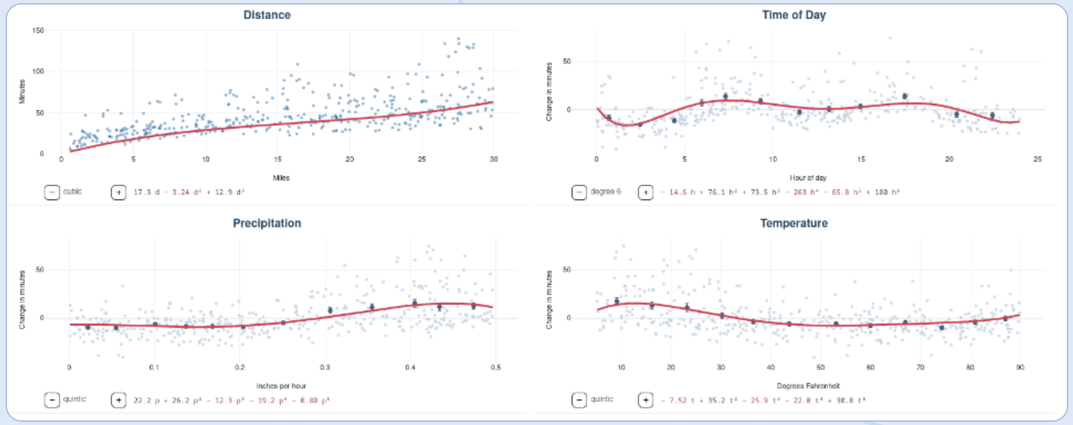
Wie kann ich mir Pre-Training vorstellen?



2

mehr Dimensionen

komplexere Funktion



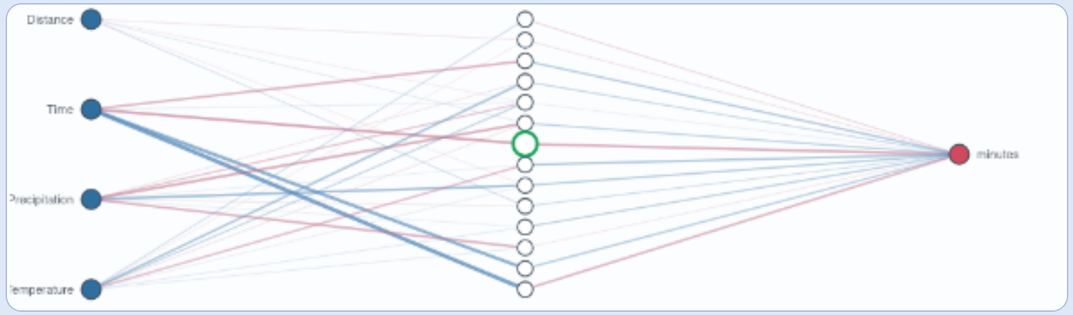
Architektur-Entscheidung

≈ wie viele Vektor-Dimensionen möglich

! Inhalt nicht vom Menschen vorgeschrieben

+ Entscheidung, wie viele Layer

≈ wie viele Zwischenrechenschritte finden statt



Das passiert für jeden Token

+ Attention = man merkt sich die Zwischenergebnisse als Kontext

Wie wird der Output „gezüchtet“?

Data Preparation

1 Data Collection
› Text, Bilder, Video, Code, …

2 Data Processing
› bereinigen
› „Tokenisieren“: jedes Wortteil kriegt eine Registernummer

Pre-Training: Basismodell erstellen

3 Model Design
› Festlegen der Architektur
› Ziel fürs Modell: möglichst richtiges Ergebnis
› korrigiert sich selbst

4 Pre-Training
› Input: alle Tokens + sehr viel Rechenleistung
› Welches nächste Token ist am wahrscheinlichsten?
› Sinnebenen und Wahrscheinlichkeiten entwickeln sich: „Embedding“

Post-Training: Assistent

5 Supervised Fine-Tuning
› Input: gute Frage-Antwort-Paare
› Ergebnis: kennt das Antwort-Format

6 Reward Modeling
› Qualität der Antwort wird gescored, um gewünschtes Verhalten einzutrainieren

7 Alignment „in unserem Sinne“
› Sicherheitsregeln · Charakter

8 Evals
› Capabilities + Propensity
› Testen der Sicherheitsvorkehrungen

Fähigkeiten und Fehlerquellen

- aus der Natur eines LLMs
- aus der Trainingspipeline
- Was soll die KI eigentlich machen?
- Wie gut verstehen wir, was die KI kann?

Was aus Natur und Entwicklung von LLMs folgt

Eigenschaft | Stärke | Schwäche



↗ Interaktiv öffnen: Felder anklicken, Pfade und Trainingsschritte sehen

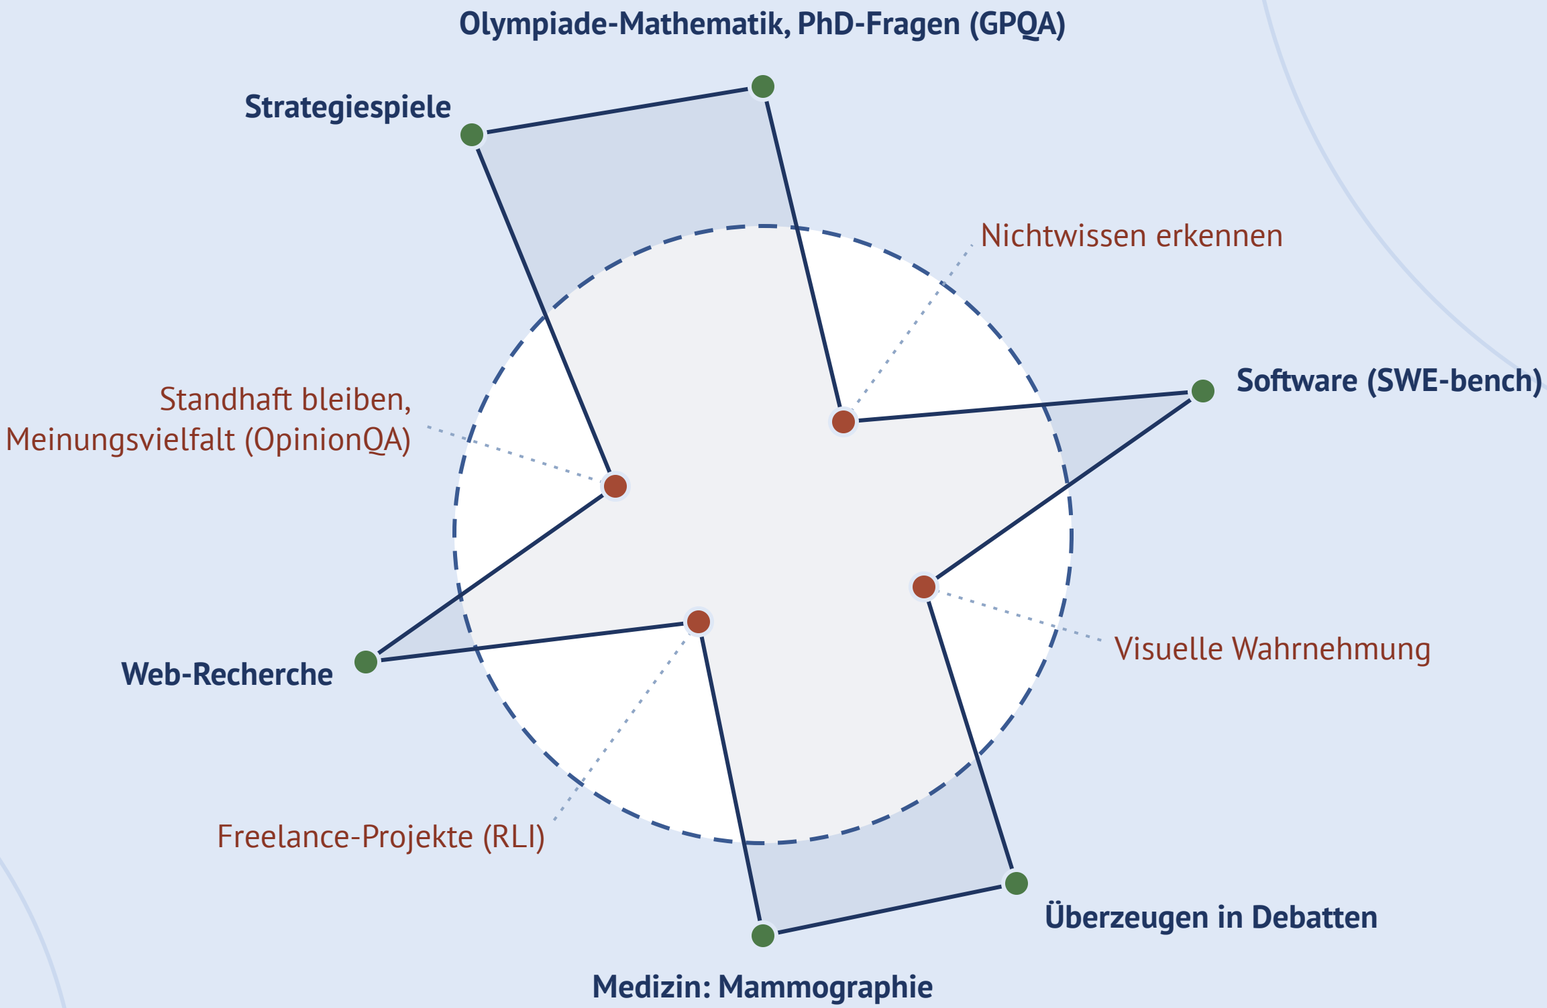
[3]–[14] Quellen auf Folie 13

TRAININGSPIPELINE

1 Data Collection
2 Data Processing
3 Model Design
4 Pre-Training
5 Supervised Fine-Tuning
6 Reward Modeling
7 Alignment
8 Evals

Jagged Frontier

- - - menschliches Niveau
- außen: KI besser
- innen: KI schlechter



Specification Gaming

„Aufgabe erfüllt, Ziel verfehlt“



Alignment ist schwer

Was sind unsere Werte?

Harte Regeln vs. im Sinne des Users

Dual-Use

„Sag mir, wann in der Mall die meisten Menschen sind.“

TRAININGSPIPELINE

1 Data Collection

2 Data Processing

3 Model Design

4 Pre-Training

5 Supervised Fine-Tuning

6 Reward Modeling
› Antwort wird gescored

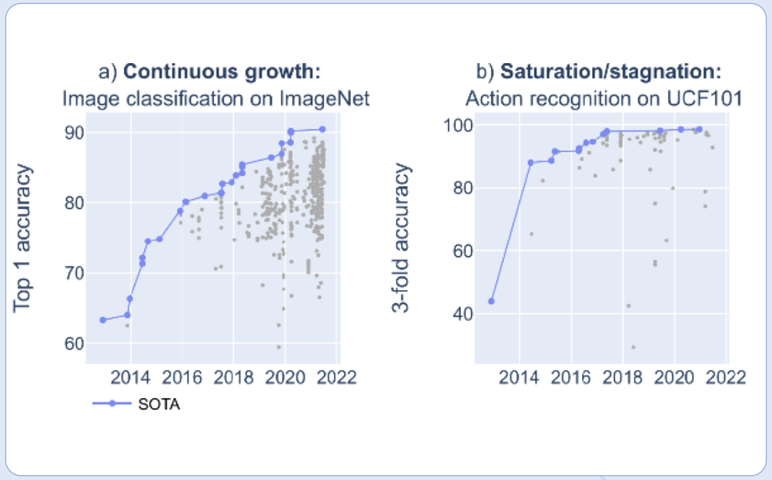
7 Alignment
› Sicherheitsregeln · Charakter

8 Evals

Eval awareness: KI ist bewusst, dass sie einem Test unterzogen wird. Davon hängt ihre Leistung ab.

Wir messen nur Proxies: nur Indizien für tatsächliche Leistung

Zu leicht / zu schwer → geringe Aussagekraft



15

Evals sind schwer

Externe Validität außerhalb von Laborbedingungen?

TRAININGSPIPELINE

1 Data Collection
2 Data Processing
3 Model Design
4 Pre-Training
5 Supervised Fine-Tuning
6 Reward Modeling
7 Alignment

8 Evals
› Capabilities + Propensity
› Sicherheitsvorkehrungen testen

Quellen

Fußnoten

[1] Joseph Lochlann Smith, „MythBusting Large Language Models“, Medium — medium.com/@joelochlannsmith/mythbusting-large-language-models-2f4ef31a7ce1

[2] Jeff Iuliano, 2026

[3] Salvi et al., „On the conversational persuasiveness of GPT-4“, Nature Human Behaviour 2025

[4] Rein et al., „GPQA: A Graduate-Level Google-Proof Q&A Benchmark“, COLM 2024

[5] Wei et al., „BrowseComp: A Simple Yet Challenging Benchmark for Browsing Agents“, OpenAI 2025

[6] McKinney et al., „International evaluation of an AI system for breast cancer screening“, Nature 2020

[7] Trinh et al., „Solving olympiad geometry without human demonstrations“ (AlphaGeometry), Nature 2024

[15] Ott et al., „Mapping global dynamics of benchmark creation and saturation in artificial intelligence“, Nature Communications 2022

[8] Jimenez et al., „SWE-bench: Can Language Models Resolve Real-World GitHub Issues?“, ICLR 2024

[9] Silver et al., „A general reinforcement learning algorithm …“ (AlphaZero), Science 2018

[10] Wei et al., „SimpleQA: Measuring short-form factuality in large language models“, OpenAI 2024

[11] Fu et al., „BLINK: Multimodal Large Language Models Can See but Not Perceive“, ECCV 2024

[12] Mazeika et al., „Remote Labor Index“, CAIS & Scale AI 2025

[13] Sharma et al., „Towards Understanding Sycophancy in Language Models“, ICLR 2024

[14] Santurkar et al., „Whose Opinions Do Language Models Reflect?“ (OpinionQA), ICML 2023

Weitere Quellen

Trainingspipeline (Folien 5–7): Ouyang et al., „Training language models to follow instructions with human feedback“, NeurIPS 2022

Folie 11: OpenAI, „Faulty Reward Functions in the Wild“ (CoastRunners-Video)